

CycleGAN

Eka Fitri Ramadani (H071191043), Alike Oktaviani (H071191057), Rahmi (H071191007)
Departmen Matematika
Universitas Hasanuddin

CONTENTS

I	Introduction	1
II	Problem Definition	1
III	Proposed Solutions	1
IV	Research Methodology	2
V	Analysis and Interpretation	2
VI	Conclusions and Recommendations	2
	References	3

LIST OF FIGURES

1	(a) Model ini berisi dua fungsi pemetaan $G : X \rightarrow Y$ dan $F : Y \rightarrow X$, dan associated adversarial discriminators D_Y dan D_X . D_Y mendorong G untuk menerjemahkan X menjadi keluaran yang tidak dapat dibedakan dari domain Y , dan sebaliknya untuk D_X , F , dan X . Untuk lebih mengatur pemetaan, diperkenalkan dua "silus kehilangan konsistensi" atau "cycle consistency losses" yang menangkap intuisi bahwa jika diterjemahkan dari satu domain ke domain yang lain dan kembali lagi kita harus tiba di tempat kita mulai: (b) forward cycle consistency loss: $x \rightarrow G(x) \rightarrow F(G(x)) \approx x$ dan (c) backward cycle consistency loss: $y \rightarrow F(y) \rightarrow G(F(y)) \approx y$	2
2	Gambar Hasil	3
3	Gambar Asli	3

LIST OF TABLES

I	FCN-scores, evaluated on Cityscapes labels→photos.	2
II	Classification performance of photo→labels cityscapes.	2

CycleGAN

Abstract—Terjemahan Gambar-ke-Gambar atau Image-to-Image Translation bertujuan untuk mempelajari cara memetakan gambar domain X ke gambar kedua, domain target Y yang berbeda. Jika data latih berpasangan tidak tersedia, maka disajikan pendekatan untuk belajar menerjemahkan gambar dari domain sumber X ke domain target Y tanpa adanya contoh berpasangan. Agar pemetaannya tidak terbatas, pemetaan $G: X \rightarrow Y$ digabungkan dengan pemetaan $F: Y \rightarrow X$ dan memperkenalkan cycle consistency loss untuk menegakkan $F(G(X)) \approx X$ dan sebaliknya. Terjemahan Gambar-ke-Gambar atau Image-to-Image Translation tanpa menggunakan "paired sample" dapat dicapai melalui model cycleGAN. Dari hasil yang diperoleh dapat dipelajari pentingnya adversarial loss, cycle consistency loss, dan membandingkan metode dengan beberapa varian metode lainnya.

Kata kunci: *cycleGAN, cycle consistency losses, associated adversarial discriminators, forward cycle consistency, backward cycle consistency*

I. INTRODUCTION

Pada laporan ini membahas tentang salah satu jenis algoritma Generative Adversarial Networks (GANs), yaitu Cycle Generative Adversarial Networks (Cycle GANs). Generative Adversarial Networks (GANs) adalah salah satu dari algoritma Unsupervised Learning yang ada pada machine learning sejak tahun 2014, dimana algoritma ini menggunakan 2 neural networks atau jaringan syaraf buatan yang terdiri atas Generator dan Diskriminator. Dengan adanya struktur seperti itu dapat menghasilkan suatu data sintesis baru yang menyerupai bentuk asli pada inputnya. Sedangkan Cycle Generative Adversarial Networks adalah jenis dari algoritma GANs yang memiliki kemampuan dalam Penerjemahan Gambar atau Image Translation.

Perbedaannya pada Cycle GANs data yang dimiliki harus memiliki gambar yang terbagi menjadi 2 bagian atau domain untuk dapat dipasangkan, sehingga menghasilkan gambar sintesis yang baru berdasarkan hasil pasangan tersebut. Implementasi dari Cycle GANs ini digunakan untuk Season Translation, Object Transfiguration, Generating Photos from Paintings, dan Style Transfer.

Laporan ini menggunakan algoritma Cycle GANs dengan harapan data sintesis baru yang dihasilkan oleh algoritma tersebut mampu menandingi performa dari data nyata atau real yang menjadi benchmark awal.

II. PROBLEM DEFINITION

Terjemahan Gambar-ke-Gambar atau Image-to-Image Translation merupakan masalah dalam class of vision and graphics yang bertujuan untuk mempelajari pemetaan antara gambar input dan gambar output menggunakan serangkaian pelatihan pasangan gambar. Namun, dalam beberapa kasus, data pelatihan berpasangan tidak tersedia.

Misalnya, untuk melatih model Image-to-Image Translation, kita membutuhkan dataset "paired sample", yaitu jika kita ingin mentransfer lukisan ke foto asli, kita akan membutuhkan ratusan lukisan dan real - foto kehidupan dari mana karya seni itu dilukis. Namun, tantangan yang dihadapi adalah, tidak mungkin kita menemukan "gambar zebra berpasangan" untuk kuda karena hal semacam itu tidak ada sama sekali.

III. PROPOSED SOLUTIONS

Terjemahan Gambar-ke-Gambar atau Image-to-Image Translation tanpa menggunakan "paired sample" dapat dicapai melalui model cycleGAN yang tidak memerlukan "paired sample" dalam pelatihan untuk mencapai transformasi. Diperkenalkan oleh Jun-yan Zhu dan rekan-rekannya di UC Berkeley pada tahun 2017, cycleGAN menghadirkan cara baru untuk melakukan Terjemahan Gambar-ke-Gambar, meskipun masih membutuhkan sekumpulan gambar kuda dan sekumpulan gambar zebra dalam pelatihan, gambar kuda dan zebra tidak perlu lagi berkorelasi langsung satu sama lain.

CycleGAN atau Cycle-Consistent GAN adalah jenis generative adversarial network untuk Terjemahan Gambar-ke-Gambar yang tidak berpasangan. Untuk dua domain X dan Y, CycleGAN mempelajari pemetaan $G: X \rightarrow Y$ and $F: Y \rightarrow X$. Kebaruannya terletak pada upaya untuk memaksakan intuisi bahwa pemetaan ini harus saling terbalik dan bahwa kedua pemetaan harus bijeksi. Hal ini dicapai melalui cycle consistency loss yang mendorong $F(G(x)) \approx x$ and $G(F(y)) \approx y$. Menggabungkan loss ini dengan adversarial losses pada X dan Y menghasilkan tujuan penuh untuk Terjemahan Gambar-ke-Gambar yang tidak berpasangan. Untuk pemetaan $G: X \rightarrow Y$ dan diskriminatornya D_Y , kami memiliki tujuan:

$$\mathcal{L}_{GAN}(G, D_Y, X, Y) = \mathbb{E}_{y \sim p_{data}(y)} [\log D_Y(y)] + \mathbb{E}_{x \sim p_{data}(x)} [\log(1 - D_Y(G(x)))]$$

dimana G mencoba untuk menghasilkan gambar $G(x)$ yang terlihat mirip dengan gambar dari domain Y, sedangkan D_Y mencoba untuk membedakan antara sampel yang diterjemahkan $G(x)$ dan sampel nyata y . Loss serupa dipostulatkan untuk pemetaan $F: Y \rightarrow X$ dan diskriminatornya D_X . Cycle Consistency Loss mengurangi ruang kemungkinan fungsi pemetaan dengan menerapkan forward and backwards consistency.

$$\mathcal{L}_{cyc}(G, F) = \mathbb{E}_{x \sim p_{data}(x)} [\|F(G(x)) - x\|_1] + \mathbb{E}_{y \sim p_{data}(y)} [\|G(F(y)) - y\|_1]$$

Tujuan lengkapnya adalah:

$$\mathcal{L}_{GAN}(G, F, D_X, D_Y) = \mathcal{L}_{GAN}(G, D_Y, X, Y) + \mathcal{L}_{GAN}(F, D_X, X, Y) + \lambda \mathcal{L}_{cyc}(G, F)$$

Dimana, laporan ini bertujuan untuk memecahkan:

$$G^*, F^* = \arg \min_{G, F} \min_{D_X, D_Y} \mathcal{L}_{GAN}(G, F, D_X, D_Y)$$

Untuk arsitektur menggunakan:

- two stride-2 convolutions, beberapa residual blocks, dan two fractionally strided convolutions dengan stride 1/2.
- Normalisasi instan.
- PatchGAN untuk diskriminator.
- Least Square Loss untuk tujuan GAN.




Fig. 1. (a) Model ini berisi dua fungsi pemetaan $G : X \rightarrow Y$ dan $F : Y \rightarrow X$, dan associated adversarial discriminators D_Y dan D_X . D_Y mendorong G untuk menerjemahkan X menjadi keluaran yang tidak dapat dibedakan dari domain Y , dan sebaliknya untuk D_X , F , dan X . Untuk lebih mengatur pemetaan, diperkenalkan dua "silus kehilangan konsistensi" atau "cycle consistency losses" yang menangkap intuisi bahwa jika diterjemahkan dari satu domain ke domain yang lain dan kembali lagi kita harus tiba di tempat kita mulai: (b) forward cycle consistency loss: $x \rightarrow G(x) \rightarrow F(G(x)) \approx x$ dan (c) backward cycle consistency loss: $y \rightarrow F(y) \rightarrow G(F(y)) \approx y$

IV. RESEARCH METHODOLOGY

Dalam laporan ini, dataset yang digunakan adalah dataset yang berasal dari <http://efrosgans.eecs.berkeley.edu/cyclegan/datasets/>, dimana pada dataset tersebut terdapat beberapa folder. Dan pretrained model menggunakan dataset yang berasal dari http://efrosgans.eecs.berkeley.edu/cyclegan/pretrained_models/.

Laporan ini mengadopsi arsitektur generative networks dari Johnson et al, yang telah menunjukkan hasil yang mengesankan untuk neural style transfer dan super resolutions. Jaringan ini berisi tiga convolutions, beberapa residual blocks, two fractionally strided convolutions dengan stride 1/2, dan satu convolutions yang memetakan fitur ke RGB. Laporan ini menggunakan 6 blocks untuk 128×128 gambar dan 9 blok untuk 256×256 dan gambar pelatihan dengan resolusi lebih tinggi. Laporan ini menggunakan normalisasi instance. Untuk jaringan discriminator menggunakan 70×70 PatchGANs, yang bertujuan untuk mengklasifikasikan apakah 70×70 overlapping image patch adalah nyata atau palsu.

Untuk training, laporan ini menerapkan dua teknik terbaru yang berfungsi untuk menstabilkan prosedur training model. Pertama, untuk LGAN, laporan ini mengganti log negatif seperti tujuan mata pencaharian dengan least-squares loss. Kerugian ini lebih stabil selama training dan menghasilkan kualitas yang hasilnya lebih tinggi. Khususnya, untuk kerugian GAN $\mathcal{L}_{GAN}(G, D, X, Y)$, training G untuk minimize $\mathbb{E}_{p_{data}(x)} [(D(G(x)) - 1)^2]$ dan training D untuk minimize $\mathbb{E}_{p_{data}(y)} [(D(y) - 1)^2] + \mathbb{E}_{p_{data}(x)} [D(G(x))^2]$.

Kedua, untuk mengurangi osilasi model, laporan ini mengikuti strategi Shrivastava et al. dan memperbarui

discriminator menggunakan riwayat image yang dihasilkan daripada yang dihasilkan oleh generator terbaru. Laporan ini menyimpan buffer image yang menyimpan 50 image yang telah dibuat sebelumnya.

Untuk semua percobaan, laporan ini menetapkan $\lambda = 10$ dalam. Laporan ini menggunakan Adam solver dengan ukuran batch 1. Semua jaringan dilatih dari awal dengan learning rate 0,0002. Laporan ini mempertahankan learning rate yang sama untuk 100 epochs dan secara linier meluruhkan laju ke nol selama 100 epochs.

V. ANALYSIS AND INTERPRETATION

Dengan membandingkan metode cycleGAN yang digunakan dengan metode terbaru untuk terjemahan gambar-ke-gambar tanpa menggunakan "paired sample", diperoleh hasil seperti pada tabel I dan II. Adapun metode - metode yang digunakan untuk melakukan perbandingan, yaitu :

- CoGAN Metode ini mempelajari satu generator GAN untuk domain X dan satu untuk domain Y , dengan bobot bersama pada beberapa lapisan pertama untuk representasi laten bersama.
- Pixel loss + GAN menggunakan adversarial loss untuk melatih terjemahan dari X ke Y
- Feature loss + GAN Kami juga menguji varian di mana loss L1 dihitung melalui fitur gambar dalam menggunakan pretrained network (VGG-16), bukan melalui nilai piksel RGB.
- BiGAN/ALI GANs, tanpa syarat mempelajari generator $G : Z \rightarrow X$, yang memetakan noise acak Z ke gambar X .

Loss	Per-pixel acc.	Per-class acc.	Class IOU
CoGAN	0.40	0.10	0.06
BiGAN/ALI	0.19	0.06	0.02
Pixel loss + GAN	0.20	0.10	0.04
Feature loss + GAN	0.06	0.04	0.01
CycleGAN (ours)	0.52	0.17	0.11

TABLE I. FCN-SCORES, EVALUATED ON CITYSCAPES LABELS \rightarrow PHOTOS.

Loss	Per-pixel acc.	Per-class acc.	Class IOU
CoGAN	0.45	0.11	0.08
BiGAN/ALI	0.41	0.13	0.07
Pixel loss + GAN	0.47	0.11	0.07
Feature loss + GAN	0.50	0.10	0.06
CycleGAN (ours)	0.58	0.22	0.16

TABLE II. CLASSIFICATION PERFORMANCE OF PHOTO \rightarrow LABELS CITYSCAPES.

Adapun hasil dari proses Terjemahan Gambar-ke-Gambar atau Image-to-Image Translation pada laporan ini dapat dilihat pada fig 2 dan fig 3.

VI. CONCLUSIONS AND RECOMMENDATIONS

Terjemahan Gambar-ke-Gambar atau Image-to-Image Translation tanpa menggunakan "paired sample" dapat dicapai melalui model cycleGAN. Dari hasil yang diperoleh dapat dipelajari pentingnya adversarial loss, cycle consistency



Fig. 2. Gambar Hasil



Fig. 3. Gambar Asli

loss, dan membandingkan metode dengan beberapa varian metode lainnya.

Berdasarkan laporan ini, algoritma Cycle GAN terbukti memiliki performa yang cukup baik untuk melakukan Terjemahan Gambar-ke-Gambar.

REFERENCES

- [1] Jun-Yan Zhu*, Taesung Park*, Phillip Isola, and Alexei A. Efros. "Unpaired Image-to-Image Translation using Cycle-Consistent Adversarial Networks", in IEEE International Conference on Computer Vision (ICCV), 2017. Diakses pada 23 Juni 2022.
- [2] Paramadhan, Anugrah Akbar, and Guntur Eka Saputra. "Cycle generative adversarial networks algorithm with style transfer for image generation." arXiv preprint arXiv:2101.03921 (2021). Diakses pada 21 Juni 2022.